

演化計算專題研究成果報告（階段三）： 約束滿足機制、超參數自適應動力學與規格作弊 防範

李承博
國立中央大學

2026 年 5 月

Abstract

本階段研究深入探討演化演算法 (Evolutionary Algorithm, EA) 在複雜迷宮地形設計問題中之「約束滿足 (Constraint Satisfaction)」與「超參數自適應 (Self-Adaptation)」動力學特徵。本研究設計並實作四種演化架構變體，分別針對固定懲罰係數約束、個體自適應突變率、個體自適應懲罰係數及基於全域啟發式之適應突變率進行系統性消融實驗。透過 30 組獨立實驗與五組雙樣本統計推論檢定 (F -Test 與 t -Test)，實驗證實外部固定約束能有效引導演化朝合法空間搜尋而不損及最佳化效能 ($p = 0.354$)；同時量化了參數自學在有限評估預算下所需承擔之「學習成本」($p = 5.11 \times 10^{-12}$)。此外，本研究成功捕捉到自適應懲罰系統誘發之「規格作弊 (Specification Gaming)」重大失效案例 ($p = 1.27 \times 10^{-8}$)，個體藉由將懲罰權重演化歸零規避規則，導致實質解品質全面崩潰。綜合實驗成果，本研究確立了健全演化最佳化系統之設計邊界準則。

1 研究背景與實驗模型配置

在 GPac 地圖生成等高維離散結構設計中，可行解必須嚴格滿足通道連通性與空間規則等硬性幾何約束。為解構約束機制與超參數自我調節對演化搜尋效率之影響，本研究設計四種主要演化架構配置：

- **Green 1c0 (固定懲罰約束滿足)**：引入係數為 0.2 之固定外部懲罰項，建立帶約束引導之演化基準。
- **Green 1c1 (個體自適應突變率)**：將突變率編碼至個體染色體中，隨演化世代由個體自發調整。
- **Yellow 1c (個體自適應懲罰係數)**：允許個體動態調節自身所承受之懲罰權重。
- **Red 1c (全域啟發式適應突變率)**：建立全域啟發式監控規則，統一在各世代宏觀調控族群之突變率。

2 演化動力學與實驗結果分析

所有實驗均遵循 30 組獨立蒙地卡羅運行規範，單次運行給定 2,000 次適應度評估預算。

2.1 Green 1c0：固定懲罰約束滿足架構

Green 1c0 之適應度收斂軌跡如圖 1 所示。




Figure 1: Green 1c0 效能學習曲線（適應度 vs. 演化世代）

動力學分析： Green 1c0 展現了穩健且單調遞增的收斂趨勢。儘管受到額外懲罰機制的約束壓制，其原始適應度（Raw Fitness）依然能達到與階段二無約束基準（Green 1b）相近之水準，證明外部施加之固定懲罰梯度能有效引導演化搜尋在合法空間內高效推進，未誘發嚴重的過早收斂或搜尋停滯。

2.2 Green 1c1：個體基因自適應突變率

Green 1c1 之適應度收斂曲線與個體突變率演化動態如圖 2 所示。




Figure 2: Green 1c1 實驗結果：適應度收斂曲線（上）與個體突變率分布動態（下）

動力學分析：從突變率分布箱型圖可清晰觀察到，族群之突變率自多樣分布最終自主收斂至 0.20 左右，該收斂值與人為設定之專家經驗值高度契合。此現象證實個體基因自適應機制具備自主定位合適超參數之能力；然而由於初期突變率波動較大，其適應度收斂坡度相對平緩。

2.3 Yellow 1c：個體自適應懲罰係數與規格作弊

Yellow 1c 之適應度收斂與懲罰係數演化趨勢如圖 3 所示。




Figure 3: Yellow 1c 實驗結果：適應度收斂曲線（上）與懲罰係數崩跌動態（下）

動力學分析：如箱型圖所示，懲罰係數（Penalty Coefficient）自初始值 0.5 迅速單調驟跌並趨近於零。此現象揭示了演化最佳化中典型的「規格作弊（Specification Gaming）」：演化個體「發現」與其耗費代價去建構滿足連通約束的複雜地圖，不如直接將自身的懲罰倍率演化降至最低以規避扣分機制。這導致演算法產生嚴重的目標偏移，無法產出具備實用價值的解。

2.4 Red 1c：基於全域啟發式之適應突變率

Red 1c 之收斂曲線與全域突變率動態如圖 4 所示。




Figure 4: Red 1c 實驗結果：適應度收斂曲線（上）與全域突變率排程動態（下）

動力學分析： Red 1c 的突變率箱型圖在各世代均呈現單一數值之扁平特徵。這是由於其採用宏觀系統導向的全域適應機制，所有個體在同一代中均共享由監控模組動態計算出的突變率，而非交由個體基因微觀演化。系統根據演化世代推進自適應衰減突變強度，成功引導適應度穩定平滑上升，展現了宏觀啟發式規則調控的高效性。

3 演化變體之推論統計檢驗

為客觀量化五組演化架構之實質差異，本研究針對各變體 30 組獨立實驗之最佳原始適應度 (Best Raw Fitness) 進行雙樣本假設檢定。首先透過雙樣本 F 檢定評估群體「穩定度 (變異數同質性)」，進而在適當變異數假設下透過雙樣本 t 檢定評估其「演化效能 (平均表現差異)」，顯著水準統一設定為 $\alpha = 0.05$ 。

3.1 檢定一：Green 1c0 vs. Green 1b（固定懲罰機制之有效性）

Table 1: Green 1c0 (固定懲罰) 與 Green 1b (無約束基準) 統計檢定結果

統計檢定指標	Green 1c0 (固定懲罰)	Green 1b (基準)	推論檢定結論
平均表現 (Mean)	-9.273	-8.200	無顯著差異 穩定度相當
變異數 (Variance)	25.088	14.521	
F 檢定 p 值		0.146	變異數同質 ($p > 0.05$) 效能無顯著差異 ($p > 0.05$)
t 檢定 p 值		0.354	

成因探討：檢定數據顯示固定懲罰模型與無約束基準在效能與穩定度上均無顯著差異 ($p > 0.05$)。這證明在 0.2 的固定懲罰引導下，演化演算法依然能順利探索至高品質解空間，並未因硬性約束的加入而陷入嚴重的局部次佳解陷阱，成功兼顧了解的合法性與搜尋效率。

3.2 檢定二：Green 1c0 vs. Green 1c1（約束引導 vs. 自適應突變）

Table 2: Green 1c0 (固定懲罰) 與 Green 1c1 (自適應) 統計檢定結果

統計檢定指標	Green 1c0 (固定懲罰)	Green 1c1 (自適應)	推論檢定結論
平均表現 (Mean)	-9.273	-16.153	極高度顯著差異 穩定度有差異
變異數 (Variance)	25.088	10.865	
F 檢定 p 值		0.013	變異數異質 ($p < 0.05$) Green 1c0 顯著較優
t 檢定 p 值		7.80×10^{-8}	

成因探討：固定約束模型 Green 1c0 顯著優於自適應突變模型 Green 1c1 ($p = 7.80 \times 10^{-8}$)。這顯示在高維地圖生成任務中，由架構師給定專家先驗參數與明確懲罰梯度的系統，效能大幅領先於單純開放個體自學超參數之架構；1c0 較高的變異數亦反映其在解空間中維持了較廣泛的探索廣度。

3.3 檢定三：Green 1c1 vs. Green 1b（自適應機制之學習成本量化）

Table 3: Green 1c1 (自適應) 與 Green 1b (固定 0.2) 統計檢定結果

統計檢定指標	Green 1c1 (自適應)	Green 1b (固定 0.2)	推論檢定結論
平均表現 (Mean)	-16.153	-8.200	極高度顯著差異 穩定度相當
變異數 (Variance)	10.865	14.521	
F 檢定 p 值		0.219	變異數同質 ($p > 0.05$) Green 1b 顯著較優
t 檢定 p 值		5.11×10^{-12}	

成因探討：固定超參數之基準展現壓倒性優勢 ($p = 5.11 \times 10^{-12}$)。此結果具體揭示了自適應機制之「學習成本 (Learning Cost)」：在 2,000 次評估限制之短跑實驗中，1c1 必須分配演化世代與樣本多樣性去調校突變率，致使其有效搜尋深度遠不及直接承襲人類先驗知識 (0.2) 之 Green 1b。

3.4 檢定四：Red 1c vs. Green 1c1 (全域宏觀調控 vs. 個體微觀演化)

Table 4: Red 1c (全域適應) 與 Green 1c1 (個體自適應) 統計檢定結果

統計檢定指標	Red 1c (全域適應)	Green 1c1 (個體自適應)	推論檢定結論
平均表現 (Mean)	-16.007	-16.153	無顯著差異
變異數 (Variance)	9.105	10.865	穩定度相當
F 檢定 p 值		0.318	變異數同質 ($p > 0.05$)
t 檢定 p 值		0.858	表現高度一致

成因探討：全域啟發式調整與個體微觀演化在收斂均值與穩定度上幾乎完全一致 ($p = 0.858$)。此結果證明：只要自適應架構具備合理的收斂牽引力，無論是自全域監控視角宏觀調節，抑或由微觀染色體競爭篩選，演算法均能在統計學意義上達成等價之參數優化平衡點。

3.5 檢定五：Yellow 1c vs. Green 1c0 (規則演化失控與規格作弊崩潰)

Table 5: Yellow 1c (自適應懲罰) 與 Green 1c0 (固定懲罰) 統計檢定結果

統計檢定指標	Yellow 1c (自適應懲罰)	Green 1c0 (固定 0.2)	推論檢定結論
平均表現 (Mean)	-16.706	-9.273	極高度顯著差異
變異數 (Variance)	10.909	25.088	穩定度有差異
F 檢定 p 值		0.014	變異數異質 ($p < 0.05$)
t 檢定 p 值		1.27×10^{-8}	Green 1c0 顯著較優

成因探討：Yellow 1c 之原始適應度呈現災難性滑落 ($p = 1.27 \times 10^{-8}$)。此為「規格作弊」誘發系統性崩潰之典型例證：個體為了追求數值最佳化，將環境懲罰權重演化消除，致使演化機制生成大量殘缺、充滿阻斷且無法通行的非法地圖。由於迷宮實體完全喪失可行走連通性，實質原始適應度大幅衰退，證實失去客觀約束之演化演算法將完全喪失解題方向。

4 專題結論與演化架構設計準則

本階段透過多變體消融實驗與嚴謹的推論統計檢驗，揭示了演化動力學中「約束滿足」與「參數自適應」之深層交互機制，得出以下核心設計哲學：

1. **固定約束為系統基石：**外部合理施加之硬性懲罰項 (0.2) 能有效維護解之可行性邊界，且未對演算法之全域尋優能力構成負面箝制。
2. **嚴禁開放評價法則演化：**Yellow 1c 之規格作弊深刻揭示了開放環境約束演化之巨大風險。個體必然選擇規避懲罰而非解決問題，導致實體質量崩潰。
3. **權衡先驗知識與學習成本：**在有限算力與評估預算之短跑任務中，由專家給定之先驗參數顯著優於演算法摸索學習之自適應機制。

綜合專題三階段之研發成果，確立演化計算系統架構之黃金原則：

最穩健之最佳化系統設計，應由系統架構師於外部強制作為環境法則（約束滿足與評價指標），並僅開放內部搜尋算子（如突變率）進行適應性調節。